

UNIVERSIDADE DE SÃO PAULO
ESCOLA POLITÉCNICA
Departamento de Engenharia de Computação e Sistemas Digitais

MELODY: RECONHECIMENTO DE MÚSICAS UTILIZANDO RASPBERRY PI 3

Relatório final do projeto

Ana Vitória Abreu Murad
Andrey Rocha Reboredo
Yasmin Francisquetti Barnes

Relatório apresentado à disciplina PCS3732 — Laboratório de Processadores.

São Paulo
2026

Resumo

Este trabalho apresenta o desenvolvimento do Melody, um reconhecedor de músicas executado localmente em uma Raspberry Pi 3 B+. O sistema grava oito segundos de áudio por um microfone USB, normaliza o sinal, calcula uma Transformada de Fourier de Curto Termo, seleciona máximos locais do espectrograma e produz impressões digitais acústicas a partir de pares de picos. Os hashes são comparados com um banco SQLite por votação de deslocamentos temporais. A solução inclui interface web local, controles físicos conectados aos pinos GPIO, cadastro automatizado de músicas e cancelamento imediato da execução. Ao final do projeto, o banco continha 11 músicas e 300.057 fingerprints. Um benchmark determinístico avaliou 99 trechos de músicas cadastradas, incluindo áudio limpo, ruído e eco, e obteve 99 acertos. Em contraste, três sinais sintéticos desconhecidos não foram rejeitados, o que evidencia a necessidade de calibrar um limiar mínimo de aceitação. Na demonstração final, a gravação cadastrada de “I’m a Believer” foi reconhecida, enquanto uma versão cover e uma interpretação de outro artista não foram identificadas. Os resultados confirmam a viabilidade do processamento offline no hardware adotado, mas também delimitam o protótipo ao reconhecimento de gravações específicas.

Palavras-chave: reconhecimento de músicas; impressão digital acústica; STFT; Raspberry Pi; sistemas embarcados.

Abstract

This report presents Melody, an offline song-recognition system running on a Raspberry Pi 3 B+. The system records an eight-second audio excerpt through a USB microphone, preprocesses the signal, computes a Short-Time Fourier Transform, selects local spectrogram peaks, and creates acoustic fingerprints from peak pairs. The hashes are matched against a local SQLite database through temporal offset voting. The final prototype includes a local web interface, GPIO controls, automated song registration, and immediate execution cancellation. Its database contains 11 songs and 300,057 fingerprints. A deterministic benchmark evaluated 99 registered-song excerpts under clean, noisy, and echo conditions and correctly identified all of them. However, none of three synthetic unknown signals was rejected, showing that a calibrated acceptance threshold is still required. In the final demonstration, the registered recording of “I’m a Believer” was recognized, whereas a cover and a version by another artist were not. The results support the feasibility of offline embedded recognition while confirming that the prototype identifies specific recordings rather than compositions in general.

Keywords: song recognition; acoustic fingerprinting; STFT; Raspberry Pi; embedded systems.

Sumário

Resumo	i
Abstract	i
1 Introdução	1
1.1 Motivação e justificativa	1
1.2 Objetivos	1
1.3 Escopo	2
2 Fundamentação teórica	2
2.1 Amostragem e pré-processamento	2
2.2 DFT, FFT e STFT	2
2.3 Mapa de constelação e fingerprints	3
2.4 Correspondência por alinhamento temporal	3
3 Requisitos	4
4 Arquitetura do sistema	5
4.1 Arquitetura física	5
4.2 Arquitetura estática de software	5
4.3 Arquitetura comportamental	6
5 Implementação	7
5.1 Ferramentas, linguagens e hardware	7
5.2 Organização dos arquivos	7
5.3 Cadastro e modelo de dados	7
5.4 Interface	8
6 Metodologia de desenvolvimento	9
7 Testes e resultados	10
7.1 Estratégia e rastreabilidade	10
7.2 Suíte automatizada	11
7.3 Áudio desconhecido e versões diferentes	11
7.4 Evidências manuais	12
7.5 Situação final dos requisitos	13
8 Conclusões	13
A Comandos de reprodução	16

1 Introdução

O reconhecimento automático de músicas é uma aplicação de recuperação de informação capaz de associar um pequeno trecho de áudio a uma gravação previamente conhecida. A tarefa combina aquisição de sinais, processamento digital, extração de características, indexação e busca. Serviços comerciais demonstram que a identificação pode permanecer funcional mesmo quando o trecho é capturado por um microfone e contém ruído ou não começa no mesmo instante da referência [8].

O projeto Melody transpõe esse problema para uma plataforma embarcada de recursos limitados. Em vez de enviar áudio a um serviço externo, toda a cadeia — gravação, processamento e consulta — ocorre na Raspberry Pi e em um banco local. Essa decisão permite estudar interfaces de hardware e software, mantém o funcionamento sem Internet e torna cada etapa do algoritmo observável. A Raspberry Pi 3 B+ possui processador ARM Cortex-A53 de quatro núcleos a 1,4 GHz, 1 GB de memória e cabeçalho GPIO de 40 pinos, características suficientes para o protótipo [4].

O trabalho foi desenvolvido na disciplina PCS3732 — Laboratório de Processadores, da Escola Politécnica da Universidade de São Paulo [7].

1.1 Motivação e justificativa

Além de sua utilidade cotidiana, o reconhecimento musical é um estudo de caso adequado para a disciplina por integrar conceitos de sistemas microprocessados e processamento de sinais. O projeto exercita captura por periférico USB, acesso a GPIO, execução concorrente, persistência local e uma interface acessível por navegador. A abordagem de impressões digitais acústicas também é mais compatível com a Raspberry Pi 3 do que modelos extensos de aprendizado profundo: o banco é precalculado e a consulta utiliza operações numéricas e buscas indexadas.

O sistema foi inspirado conceitualmente na estratégia de mapa de constelação e alinhamento temporal descrita por Wang [8]. O objetivo, entretanto, não é reproduzir a escala ou a robustez de um produto comercial, mas construir uma implementação didática, verificável e extensível para um catálogo pequeno.

1.2 Objetivos

O objetivo geral é desenvolver um sistema embarcado capaz de identificar músicas previamente cadastradas a partir de trechos capturados por microfone em uma Raspberry Pi 3.

Os objetivos específicos são:

- capturar e padronizar áudio em formato mono a 16 kHz;
- obter uma representação tempo-frequência por STFT;

- extrair picos espectrais e gerar fingerprints acústicos;
- armazenar metadados e fingerprints em banco local indexado;
- reconhecer trechos por colisão de hashes e alinhamento temporal;
- permitir o controle por interface web e botões GPIO;
- automatizar o cadastro de novas músicas e a execução de testes; e
- avaliar acertos, condições adversas, rejeição e cancelamento.

1.3 Escopo

O protótipo identifica a mesma gravação que foi cadastrada, mesmo quando a consulta corresponde a outro ponto temporal ou contém perturbações moderadas. Ele não foi projetado para reconhecer apenas a melodia, letra, canto, assobio ou arranjos diferentes. Assim, a palavra “original” usada nos testes significa a versão de referência presente no banco, e não necessariamente a primeira gravação histórica da composição. Serviços em nuvem e catálogos externos também estão fora do escopo.

2 Fundamentação teórica

2.1 Amostragem e pré-processamento

Um sinal de áudio digital pode ser representado pela sequência $x[n]$, obtida em instantes igualmente espaçados. O Melody converte entradas para ponto flutuante, combina canais em mono, remove amostras inválidas e componente contínua, reamostra para 16 kHz e normaliza o pico. De acordo com o critério de Nyquist, essa taxa representa frequências de até 8 kHz, intervalo suficiente para os picos utilizados pelo sistema.

2.2 DFT, FFT e STFT

A Transformada Discreta de Fourier (DFT) de uma janela com N amostras é

$$X[k] = \sum_{n=0}^{N-1} x[n]e^{-j2\pi kn/N}, \quad 0 \leq k < N. \quad (1)$$

A Transformada Rápida de Fourier (FFT) calcula a mesma DFT com decomposições que reduzem a ordem de custo de $O(N^2)$ para $O(N \log N)$; a formulação de Cooley e Tukey é uma referência clássica desse método [1]. Como uma única DFT perde a localização temporal das frequências, aplica-se uma janela móvel $w[n]$, produzindo a Transformada de Fourier de Curto Termo:

$$X(m, k) = \sum_{n=0}^{N-1} x[n + mH]w[n]e^{-j2\pi kn/N}, \quad (2)$$

em que m é o índice do quadro e H é o avanço entre quadros. Na implementação, $N = 1024$, $H = 256$, a janela é Hann e a FFT usa 2048 pontos. Em 16 kHz, isso corresponde a janelas de 64 ms, avanço de 16 ms e espaçamento espectral de aproximadamente 7,81 Hz. A magnitude é convertida para decibéis e normalizada em relação ao maior bin:

$$S_{\text{dB}}(m, k) = 20 \log_{10}(\max(|X(m, k)|, \varepsilon)) - S_{\text{max}}. \quad (3)$$

2.3 Mapa de constelação e fingerprints

Armazenar todos os bins do espectrograma seria custoso e sensível a pequenas variações. Em seu lugar, o algoritmo seleciona máximos locais entre 80 Hz e 7 kHz, acima de -35 dB. A vizinhança possui raio de 15 bins de frequência e 9 quadros no tempo, com limite de 30 picos por segundo. O resultado é um mapa de constelação esparsa, ilustrado na Figura 1.




Figura 1: Representações intermediárias da gravação cadastrada de *I'm a Believer*. Fonte: elaboração própria.

Cada pico âncora de frequência f_a é combinado com até cinco picos-alvo f_b localizados entre 0,1 s e 2,0 s depois dele. A chave antes do hash é

$$K = (\lfloor f_a \rfloor, \lfloor f_b \rfloor, \text{round}(1000\Delta t)). \quad (4)$$

O SHA-1 de K é calculado e truncado para 20 caracteres hexadecimais. O SHA-1 é usado aqui apenas como função determinística e compacta de indexação, não como mecanismo de segurança. Junto a cada hash é armazenado o instante da âncora.

2.4 Correspondência por alinhamento temporal

Para cada hash da consulta, o banco retorna ocorrências (s, t_b) , onde s é a música e t_b é o instante na referência. Calcula-se

$$\Delta = t_b - t_q, \quad (5)$$

com arredondamento de 0,1 s. Hashes provenientes do mesmo trecho tendem a votar no mesmo par (s, Δ) , mesmo quando a consulta começa em outro ponto da música. O par mais votado fornece a identificação e o deslocamento estimado. Essa coerência temporal é mais discriminante do que a simples contagem de hashes iguais [8].

3 Requisitos

A Tabela 1 consolida os requisitos finais. Os testes associados são detalhados na Seção 7.

Tabela 1: Requisitos funcionais e não funcionais.

ID	Descrição	Critério de verificação
RF01	Capturar trecho por microfone conectado à Raspberry Pi.	Gerar WAV válido após o acionamento azul.
RF02	Manter banco local de músicas cadastradas.	Consultar metadados e fingerprints persistidos no SQLite.
RF03	Gerar fingerprints para cada referência cadastrada.	Cadastrar uma música e verificar hashes associados ao seu identificador.
RF04	Gerar fingerprints do trecho capturado.	Processar uma gravação de oito segundos e obter landmarks e hashes.
RF05	Comparar a consulta aos fingerprints do banco.	Produzir votos agrupados por música e deslocamento.
RF06	Exibir título e artista da música reconhecida.	Observar resultado correto na interface e a capa quando disponível.
RF07	Informar quando não houver música compatível.	Rejeitar silêncio, sinais sintéticos e gravações não cadastradas.
RF08	Disponibilizar controle físico por GPIO.	Azul inicia; verde processa; vermelho interrompe em qualquer estado.
RNF01	Operar integralmente sem conexão com a Internet.	Executar captura, consulta e apresentação usando apenas recursos locais.
RNF02	Apresentar o resultado em até 10 s após a captura.	Cronometrar a cadeia completa no hardware-alvo.
RNF03	Executar em Raspberry Pi 3 com Raspberry Pi OS.	Realizar uma demonstração integrada no dispositivo.

ID	Descrição	Critério de verificação
RNF04	Permitir inclusão de músicas sem alterar código-fonte.	Usar <code>add_song.py</code> apenas com argumentos de linha de comando.
RNF05	Possuir arquitetura modular e código documentado e testável.	Inspecionar responsabilidades dos módulos, documentação e suíte automática.

4 Arquitetura do sistema

4.1 Arquitetura física

A Figura 2 mostra os elementos físicos. Um dispositivo externo reproduz a música, o microfone USB fornece áudio PCM à Raspberry Pi e uma tela exibe a interface web. Três entradas com *pull-up* interno são usadas: GPIO 20 (azul), GPIO 16 (verde) e GPIO 21 (vermelho). Um filtro de 200 ms no `pigpio` reduz múltiplos acionamentos mecânicos. O botão amarelo permanece visível na representação da interface, porém é deliberadamente inativo e não possui manipulador GPIO.




Figura 2: Arquitetura física do protótipo. Fonte: elaboração própria.

4.2 Arquitetura estática de software

A aplicação é dividida entre apresentação, coordenação, processamento e dados, conforme a Figura 3. O navegador envia ações e lê o estado em JSON; o Flask expõe as rotas; `RecognitionService` coordena *threads*, estados e subprocessos; `GPIOController` converte bordas de descida em ações; e módulos especializados processam o áudio. O SQLite é adequado ao catálogo local por ser incorporado ao processo, transacional e não exigir servidor separado [6].




Figura 3: Arquitetura estática de software. Fonte: elaboração própria.

A interface mantém a visualização sincronizada com o estado do serviço por meio da rota local `/api/state`. Como toda a comunicação ocorre na própria rede do protótipo, esse mecanismo não depende de serviços externos nem altera o caráter offline da solução.

4.3 Arquitetura comportamental

O fluxo de estados é apresentado na Figura 4. O botão azul inicia uma gravação assíncrona de oito segundos. Ao final, o estado muda para `ready`; o verde inicia STFT, picos, fingerprints e matching. O vermelho pode ser acionado durante gravação ou processamento: o identificador da execução é invalidado, o grupo do subprocesso recebe `SIGTERM` e, se não encerrar em 0,5 s, recebe `SIGKILL`. Isso impede que uma thread antiga publique um resultado depois do cancelamento.




Figura 4: Fluxo comportamental do reconhecimento. Fonte: elaboração própria.

5 Implementação

5.1 Ferramentas, linguagens e hardware

Foram usados Raspberry Pi 3 B+, microfone USB, cartão microSD e botões conectados ao GPIO. O software foi escrito em Python 3 sobre Raspberry Pi OS. NumPy fornece os vetores numéricos; SciPy, a reamostragem, STFT e filtros de máximos; Matplotlib, os gráficos; ALSA/`arecord`, a captura; FFmpeg, a conversão de referências; SQLite, a persistência; Flask, a interface HTTP; e HTML, CSS e JavaScript, a apresentação [3, 5, 2]. Git e GitHub foram usados para versionamento e releases.

5.2 Organização dos arquivos

As responsabilidades principais aparecem na Tabela 2. Artefatos de referência e consulta são mantidos em diretórios separados, o que facilita testes e diagnóstico.

Tabela 2: Principais diretórios e módulos.

Caminho	Responsabilidade
<code>src/audio_utils.py</code>	Conversão, mono, remoção de DC, reamostragem e normalização.
<code>src/generate_spectrogram.py</code>	STFT, espectrograma e arquivos NPZ.
<code>src/detect_peaks.py</code>	Máximos locais e mapa de constelação.
<code>src/generate_fingerprints.py</code>	Pareamento de picos e hashes.
<code>src/match_song.py</code>	Busca SQLite e votação de offsets.
<code>src/add_song.py</code>	Conversão e cadastro ou substituição de músicas.
<code>src/interface/</code>	Flask, serviço concorrente, GPIO e páginas web.
<code>database/</code>	Banco SQLite e artefatos numéricos processados.
<code>reference_songs/</code>	Arquivos de áudio de referência.
<code>plots/</code>	Espectrogramas e landmarks para inspeção.
<code>tests/</code>	Testes unitários, integração e benchmark.

5.3 Cadastro e modelo de dados

O script `add_song.py` recebe um arquivo aceito pelo FFmpeg, título, artista e capa opcional. Ele converte o áudio para WAV PCM mono a 16 kHz, executa o pipeline e insere tudo em uma transação. A opção `-replace` preserva o identificador da música, apaga fingerprints antigos e grava o novo conjunto. O banco possui a relação `songs(id, title, artist, album, cover_file)` e a relação `fingerprints(hash, song_id, offset)`,

com índices por hash e por música. A interface usa um quadro simples com nota musical quando não há capa, evitando depender de imagens externas.

Ao final, havia 11 músicas e 300.057 fingerprints (Tabela 3).


Tabela 3: Conteúdo final do banco de fingerprints.

ID	Título	Artista	Fingerprints
1	Espresso	Sabrina Carpenter	24.853
2	One True Love	Patrick Patrikios	19.531
3	I'm a Believer	Smash Mouth	26.314
4	I Can See You	Taylor Swift	40.021
5	I Think We're Alone Now	Tiffany	33.069
6	Faint	Linkin Park	23.646
7	Never Gonna Give You Up	Rick Astley	31.189
8	Femininomenon	Chappell Roan	28.864
9	Miku	Hatsune Miku	31.091
10	Alas	Karol Sevilla	12.441
11	Claroscuro	Valentina Zenere	29.038
Total			300.057


5.4 Interface

A página inicial apresenta o projeto e a página de reconhecimento concentra o estado, os controles e o cartão de resultado. Quando há identificação, são exibidos título, artista, capa (ou substituto gráfico) e votos alinhados. A antiga porcentagem de confiança foi retirada da interface por não representar uma probabilidade calibrada de acerto; sua exibição poderia induzir uma interpretação estatística incorreta. O cartão foi dimensionado para a tela do protótipo sem reduzir o espaçamento de identidade visual no cabeçalho.

As duas páginas em execução no hardware utilizado durante a apresentação são mostradas na Figura 5.



(a) Página inicial.



(b) Resultado do reconhecimento.

Figura 5: Interface final em execução na Raspberry Pi 3. Fonte: elaboração própria.

6 Metodologia de desenvolvimento

Adotou-se desenvolvimento incremental durante quatro ciclos semanais, com código executável, documentação no README e histórico no Git. Não houve release na primeira semana; foram preparadas duas releases intermediárias e uma release final. O repositório público está disponível em https://github.com/ana-vitoria-murad/PCS3732_project.

Tabela 4: Síntese dos incrementos.

Ciclo	Foco	Entrega principal
Semana 1 sem release	Estruturação	Captura, inspeção de áudio, utilitários, espectrograma e banco inicial.
Semana 2 v0.1.0	Base funcional	Refinamento do processamento, primeiros resultados e documentação.
Semana 3 v0.2.0	Pipeline completo	Cadastro automático, novas músicas, matching e evidências experimentais.
Semana 4 release final	Integração e robustez	Interface web, GPIO, cancelamento imediato, catálogo com 11 músicas e testes automatizados.

As decisões foram verificadas primeiro em módulos isolados e depois integradas. Gráficos de espectrogramas e landmarks ajudaram a inspecionar parâmetros; testes com arquivos WAV evitaram depender do microfone durante regressões; e a validação final no hardware verificou a interação física. Essa separação reduziu o custo de diagnóstico quando uma falha podia estar na aquisição, no processamento ou no controle da interface.

7 Testes e resultados

7.1 Estratégia e rastreabilidade

Foram combinados testes automatizados reprodutíveis e ensaios manuais no hardware. Os testes automáticos usam referências WAV, não acessam o microfone, não alteram o banco de produção e aplicam sementes fixas ao ruído. A Tabela 5 relaciona casos, requisitos e evidências.

Tabela 5: Rastreabilidade entre testes e requisitos.

Teste	Procedimento e resultado esperado	Requisitos	Evidência
T01	Gravar 8 s por USB e obter WAV válido.	RF01, RNF03	Demonstração integrada no hardware.
T02	Cadastrar/substituir música e preservar ID e metadados.	RF02, RF03, RNF04	test_add_song.py.
T03	Reconhecer trecho limpo central de cada uma das 11 músicas.	RF03–RF06	test_audio_pipeline.py.
T04	Avaliar três posições sob condições limpa, ruído e eco.	RF04–RF06	benchmark_recognition.py.
T05	Submeter silêncio e esperar rejeição antes do matching.	RF07	Teste automatizado aprovado.
T06	Submeter ruído, tom e acorde sintéticos e esperar ausência de match.	RF07	Falha conhecida documentada.
T07	Acionar azul, verde e vermelho no GPIO.	RF01, RF06, RF08, RNF03	Ensaio manual na apresentação.
T08	Cancelar subprocesso ativo e impedir resultado tardio.	RF08	test_cancellation.py.
T09	Executar sem APIs ou banco remoto.	RNF01	Inspeção da arquitetura e demonstração local.
T10	Medir captura–resultado na Raspberry Pi.	RNF02	Medição sistemática ainda pendente.
T11	Inspecionar módulos, documentação e histórico.	RNF05	Código-fonte, README, testes e releases.

7.2 Suíte automatizada

Em 21 de agosto de 2026, a suíte executou seis testes em 1,595 s no ambiente de desenvolvimento: cinco passaram e um foi registrado como falha esperada. Os casos aprovados cobrem substituição de música, reconhecimento das 11 referências, ruído determinístico, rejeição de silêncio e cancelamento de subprocesso. A falha esperada documenta RF07 até a introdução de um critério mínimo de aceitação.

O benchmark gerou 99 casos de músicas registradas: 11 músicas, três posições relativas (20%, 50% e 80%) e três condições. Cada trecho tinha oito segundos. A Tabela 6 apresenta o resultado obtido no ambiente de desenvolvimento; o tempo inclui a extração e a consulta em memória, mas não a captura pelo microfone e não deve ser confundido com a medição de RNF02 no hardware-alvo.

Tabela 6: Resultado do benchmark automatizado.

Condição	Corretos	Tempo médio	Votos médios
Limpo	33/33	0,124 s	942,1
Ruído (SNR de 20 dB)	33/33	0,118 s	716,5
Eco sintético	33/33	0,118 s	481,2
Total	99/99	—	—

O teste mede acurácia dentro do catálogo com trechos derivados digitalmente das próprias referências. Portanto, 100% nesses 99 casos não implica 100% em qualquer ambiente acústico. A queda de votos de áudio limpo para eco mostra que a perturbação reduz a evidência mesmo quando o vencedor permanece correto.

7.3 Áudio desconhecido e versões diferentes

Nos três casos sintéticos desconhecidos, nenhum foi rejeitado: ruído branco foi associado a *Alas* com dois votos, o tom de 440 Hz a *One True Love* com um voto e o acorde sintético à mesma música com dois votos. O matcher atual seleciona o maior agrupamento sempre que existe pelo menos uma colisão; sem limiar absoluto, razão entre primeiro e segundo colocados ou calibração por densidade, colisões esparsas podem produzir falso positivo.

Um ensaio complementar foi realizado na apresentação final com três gravações de *I'm a Believer*: a versão cadastrada no banco, uma versão cover e uma interpretação de outro artista. Apenas a versão cadastrada foi reconhecida. O resultado é coerente com o escopo: arranjo, timbre e gravação distintos alteram os picos e hashes, ainda que a composição seja a mesma. Esse ensaio é uma evidência negativa útil, mas não elimina a falha observada com sinais sintéticos; são conjuntos de teste diferentes.

7.4 Evidências manuais

Nos testes iniciais, cinco gravações reproduzidas e capturadas pelo microfone foram identificadas corretamente (Tabela 7). A porcentagem de confiança do protótipo inicial não é reproduzida porque não era calibrada e foi removida da interface final.

Tabela 7: Resultados manuais iniciais.

Música	Resultado	Votos	Offset
I'm a Believer	Correto	25	22,9 s
I Think We're Alone Now	Correto	3	60,5 s
I Can See You	Correto	31	167,9 s
Espresso	Correto	19	20,1 s
One True Love	Correto	3	30,7 s

As evidências audiovisuais cobrem diferentes etapas do desenvolvimento: os dois primeiros vídeos registram o pipeline inicial, os dois seguintes demonstram a interface visual integrada e o último documenta a comparação entre gravações da mesma composição.

- reconhecimento inicial de *I Think We're Alone Now*;
- reconhecimento inicial de *I Can See You*;
- reconhecimento de *Faint* pela interface visual;
- reconhecimento de *I'm a Believer* pela interface visual; e
- demonstração comparativa de *I'm a Believer*, reunindo no mesmo vídeo a gravação cadastrada, o cover e a versão de outro artista: [vídeo da demonstração comparativa no Google Drive](#).

7.5 Situação final dos requisitos

Tabela 8: Avaliação final dos requisitos.

ID	Situação	Justificativa
RF01– RF06	Atendidos	Pipeline completo, cinco ensaios físicos e 99/99 casos registrados no benchmark.
RF07	Parcial	Silêncio e duas versões musicais foram rejeitados, porém 0/3 sinais sintéticos desconhecidos foram rejeitados.
RF08	Atendido	Azul, verde e vermelho integrados; cancelamento possui teste automatizado. Amarelo é apenas visual e inativo.
RNF01	Atendido	Processamento, dados e interface são locais.
RNF02	Inconclusivo	O processamento automatizado foi rápido no ambiente de desenvolvimento, mas falta cronômetro da cadeia completa na Pi.
RNF03	Atendido	Protótipo integrado demonstrado em Raspberry Pi 3.
RNF04	Atendido	Quatro novas músicas foram incluídas por <code>add_song.py</code> , sem mudar o pipeline.
RNF05	Atendido qualitativamente	Módulos coesos, docstrings, testes e histórico incremental; não foram calculadas métricas estáticas formais.

8 Conclusões

O Melody atingiu o objetivo central de capturar um trecho, extrair fingerprints, consultar um catálogo local e apresentar a identificação em uma Raspberry Pi 3. A integração entre processamento de sinais, SQLite, Flask e GPIO produziu um protótipo utilizável e inteiramente offline. O cadastro automatizado levou o banco a 11 músicas sem mudanças no código, e a suíte com 99 casos confirmou regressão positiva nas três condições avaliadas.

Os resultados também mostram por que acerto dentro do catálogo e rejeição de desconhecidos são problemas diferentes. O alinhamento temporal identifica bem as referências, mas o sistema ainda não possui evidência estatística suficiente para transformar poucos votos em uma decisão de “não reconhecido”. Por esse motivo, RF07 permanece apenas parcialmente atendido e RNF02 necessita uma medição fim a fim no hardware. Essa apresentação transparente das limitações evita atribuir à solução uma robustez que os testes não demonstraram.

As principais dificuldades foram calibrar picos para gravações acústicas, organizar subprocessos sem bloquear a interface, garantir cancelamento imediato e conciliar GPIO real com testes executados fora da Raspberry Pi. Como aprendizado, destacam-se a importância de separar módulos puros de dependências físicas, usar casos determinísticos para regressão e testar também entradas que não deveriam ser reconhecidas.

Como trabalhos futuros, recomenda-se: coletar um conjunto maior de negativos reais; calibrar um limiar por número de votos, margem entre candidatos e quantidade de fingerprints; medir latência completa e consumo de recursos na Raspberry Pi; ampliar o catálogo; e avaliar parâmetros de picos em ambientes e posições de microfone variados.

Referências

- [1] COOLEY, James W.; TUKEY, John W. An algorithm for the machine calculation of complex Fourier series. **Mathematics of Computation**, Providence, v. 19, n. 90, p. 297–301, 1965. DOI: 10.1090/S0025-5718-1965-0178586-1.
- [2] PALLET'S PROJECTS. **Flask documentation**. Disponível em: <https://flask.palletsprojects.com/en/stable/>. Acesso em: 21 ago. 2026.
- [3] NUMPY DEVELOPERS. **NumPy documentation**. Disponível em: <https://numpy.org/doc/stable/>. Acesso em: 21 ago. 2026.
- [4] RASPBERRY PI LTD. **Raspberry Pi 3 Model B+: product brief**. Cambridge, s.d. Disponível em: <https://pip-assets.raspberrypi.com/categories/532-raspberry-pi-3-model-b/documents/RP-008338-DS/raspberry-pi-3-b-plus-product-brief.pdf>. Acesso em: 21 ago. 2026.
- [5] SCIPY COMMUNITY. **SciPy API reference**. Disponível em: <https://docs.scipy.org/doc/scipy/reference/>. Acesso em: 21 ago. 2026.
- [6] SQLITE CONSORTIUM. **About SQLite**. Disponível em: <https://www.sqlite.org/about.html>. Acesso em: 21 ago. 2026.
- [7] UNIVERSIDADE DE SÃO PAULO. **PCS3732 — Laboratório de Processadores**. JupyterWeb. Disponível em: <https://uspdigital.usp.br/jupyterweb/obterDisciplina?sgldis=PCS3732&verdis=2>. Acesso em: 21 ago. 2026.
- [8] WANG, Avery Li-Chun. An industrial-strength audio search algorithm. In: **INTERNATIONAL CONFERENCE ON MUSIC INFORMATION RETRIEVAL**, 4., 2003, Baltimore. **Proceedings [...]** Baltimore: ISMIR, 2003. p. 7–13. Disponível em: <https://zenodo.org/records/1416340>. Acesso em: 21 ago. 2026.

A Comandos de reprodução

Os comandos abaixo devem ser executados a partir da pasta `song-recognizer`. O ambiente virtual não faz parte da release: ele deve ser recriado a partir do arquivo `requirements.txt`.

```
# Preparação do ambiente
```

```
python -m venv .venv
```

```
source .venv/bin/activate
```

```
python -m pip install -r requirements.txt
```

```
# Testes rápidos
```

```
PYTHONPATH=src:. python -m unittest discover -s tests -v
```

```
# Benchmark completo
```

```
MPLCONFIGDIR=/tmp/melody-mpl PYTHONPATH=src:. \
```

```
python tests/benchmark_recognition.py
```

```
# Interface local com GPIO
```

```
sudo pigpiod
```

```
MELODY_ENABLE_GPIO=1 MELODY_AUDIO_DEVICE=plughw:2,0 \
```

```
PYTHONPATH=. python src/interface/app.py
```

```
# Cadastro de música
```

```
PYTHONPATH=src:. python src/add_song.py caminho/musica.mp3 \  
--title "Título" --artist "Artista"
```